Prédiction du prix des logements à Boston par régression linéaire

Dalikan N'guessan

6 octobre 2026

Résumé

Le projet consiste à prédire la valeur médiane des logements à Boston à partir de variables socio-économiques et urbaines, en utilisant un modèle de régression linéaire multiple. Le jeu de données contient 506 observations et 13 variables explicatives, ainsi qu'une variable cible continue. Après séparation aléatoire en ensemble d'entraînement et de test, le modèle est estimé par moindres carrés ordinaires. Les résultats montrent un ajustement satisfaisant : le coefficient de détermination est de 0,7509 sur les données d'entraînement et de 0,6688 sur les données de test. Le RMSE est de 4,65 milliers de dollars en apprentissage et de 4,93 milliers de dollars en test. Les diagnostics indiquent que le modèle capture bien l'essentiel de la structure de la donnée, mais que les hypothèses d'homoscédasticité et de normalité des résidus ne sont pas totalement respectées. Cette étude permet ainsi de tester une chaîne complète de travail en data science : exploration, modélisation, évaluation et diagnostic critique.

Mots-clés : régression linéaire, Boston Housing, analyse exploratoire, diagnostics du modèle, machine learning.

Table des matières

1 Introduction **3**

2 Données et analyse exploratoire **3**

2.1 Présentation du jeu de données 3
2.2 Analyse exploratoire 4
2.3 Séparation train-test 6
2.4 Modèle de régression linéaire 6
2.5 Métriques d'évaluation 6
2.6 Diagnostics du modèle 6

3 Résultats **7**

3.1 Performance du modèle 7
3.2 Interprétation des coefficients 7

4 Vérification des hypothèses du modèle **8**
4.1 Hétéroscédasticité 8
4.2 Normalité des résidus 8
4.3 Autocorrélation et multicolinéarité 9

5 Discussion et limites **9**

6 Conclusion **10**

7 Références **10**

1 Introduction

Le jeu de données Boston Housing est un exemple classique de problème de prédiction immobilière. Il décrit plusieurs quartiers de Boston au début des années 1970 et contient des informations sur la démographie, la qualité de l'environnement, l'accès aux services et les caractéristiques socio-économiques. L'objectif est d'expliquer la variable cible, la valeur médiane des logements, à partir d'un ensemble de variables explicatives.

Cette étude s'inscrit dans une logique de montée en compétence en data science. L'enjeu n'est pas seulement d'obtenir un bon score, mais surtout de maîtriser les étapes essentielles d'un projet de modélisation : nettoyage des données, analyse exploratoire, validation, interprétation et diagnostic des hypothèses. La régression linéaire est utilisée ici comme modèle de référence, car elle reste un outil simple, explicable et très utile pour comprendre les relations entre variables.

Le rapport est organisé comme suit : la section 2 présente les données et l'analyse exploratoire, la section 3 décrit la méthodologie, la section 4 expose les résultats, la section 5 analyse les hypothèses du modèle, puis la section 6 conclut la discussion et les perspectives.

2 Données et analyse exploratoire

2.1 Présentation du jeu de données

Le jeu de données comprend 506 observations et 14 variables numériques, dont 13 variables explicatives et une variable cible : *Valeur_ med_ logement*. Les différentes colonnes décrivent notamment la criminalité, la proportion de terrains résidentiels, la densité industrielle, la proximité des centres d'emploi, le nombre de pièces, la proportion de logements anciens, l'impôt foncier, le taux de population défavorisée, ainsi que l'accès aux autoroutes.

Les données ne comportent pas de valeurs manquantes. Les colonnes ont été renommées pour améliorer la lisibilité du notebook et du rapport.

TABLE 1 – Description des variables du jeu de données

Variable	Description
Taux_criminalite	Taux de criminalité par habitant
Prop_terrains_resid	Proportion de terrains résidentiels en lots de plus de 25 000 pieds carrés
Prop_acres_indus	Proportion de surface industrielle
Bordure_riviere	Variable binaire indiquant si le quartier borde la rivière
Concentration_NO2	Concentration de dioxyde d'azote
Nb_pieces_logement	Nombre moyen de pièces par logement
Prop_log_construits_av1940	Proportion de logements construits avant 1940
Dist_ponderees_emploi	Distance pondérée aux centres d'emploi
Accessibilite_autoroute	Indice d'accessibilité aux autoroutes
Taux_impot_foncier	Taux d'impôt foncier
Ratio_eleve_prof	Ratio élèves-professeurs
Prop_noirs_ville	Proportion de population noire
Pourcentage_pop_inf	Pourcentage de population défavorisée
Valeur_med_logement	Valeur médiane des logements (cible)

2.2 Analyse exploratoire

L'analyse exploratoire a mis en évidence des distributions hétérogènes pour plusieurs variables. Les histogrammes et les boxplots montrent notamment une forte asymétrie pour des variables comme le taux de criminalité et la proportion de population défavorisée. Les variables les plus liées à la cible sont le nombre de pièces, la distance aux centres d'emploi et le pourcentage de population défavorisée.

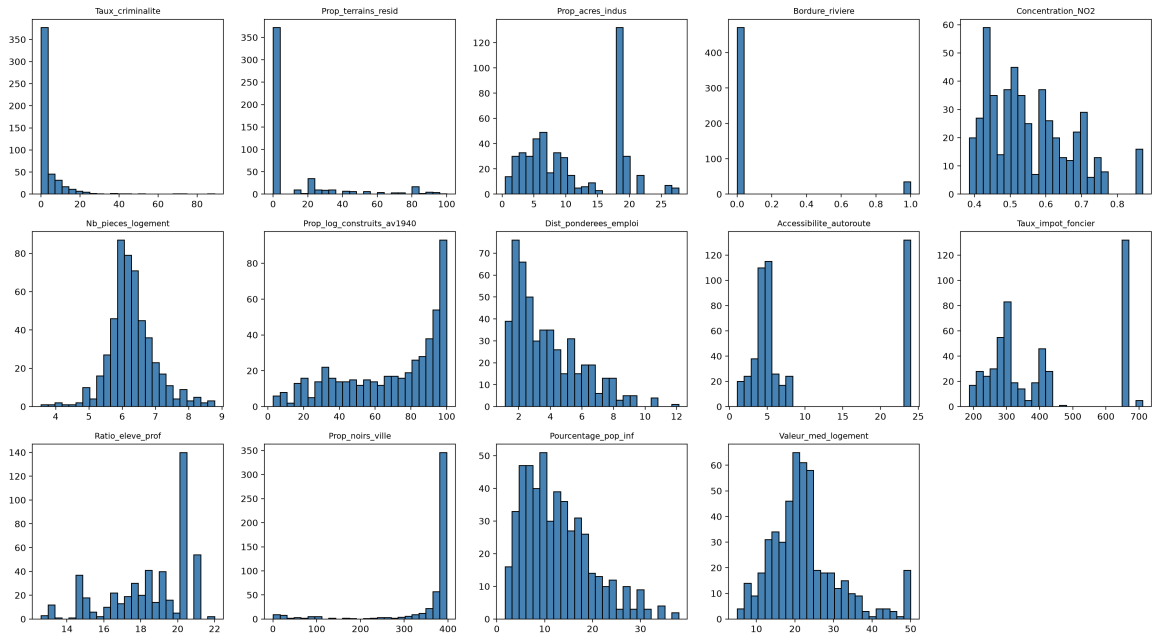


FIGURE 1 – Histogrammes des variables du jeu de données

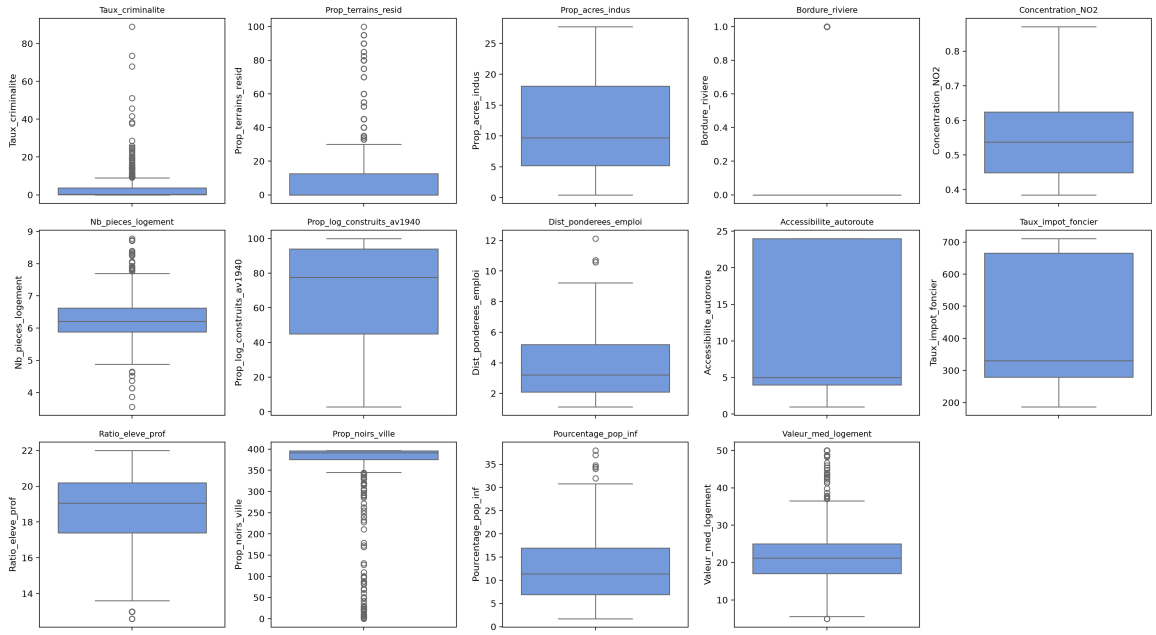


FIGURE 2 – Boxplots des variables explicatives

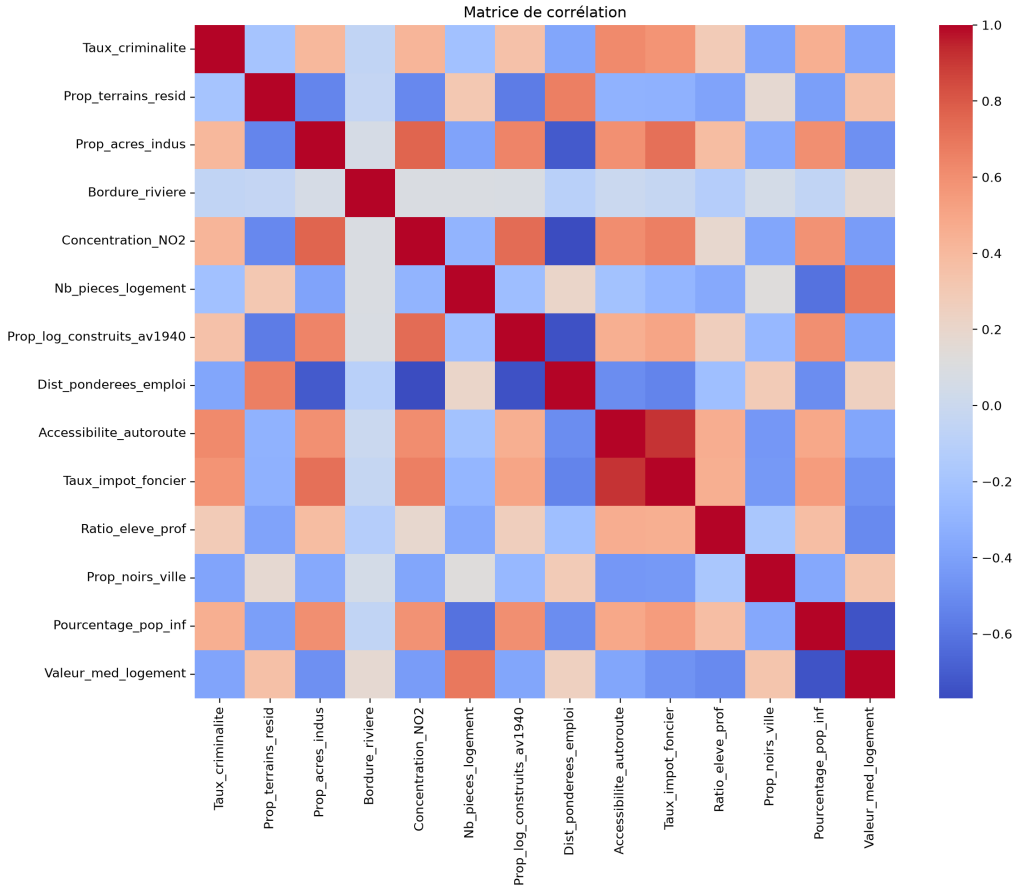


FIGURE 3 – Matrice de corrélation entre variables

Les nuages de points confirment la présence d'une relation marquée entre la valeur du logement et les variables les plus corrélées à la cible. La corrélation la plus forte en valeur

absolue est observée pour le nombre de pièces, tandis que le pourcentage de population défavorisée est associé à une baisse de la valeur des logements. La matrice de corrélation montre aussi qu'il existe des couples de variables fortement corrélés, notamment entre l'accessibilité aux autoroutes et le taux d'impôt foncier, ce qui justifie la surveillance de la multicolinéarité.

2.3 Séparation train-test

Les données sont divisées en deux sous-ensembles : 80% pour l'entraînement et 20% pour le test, avec un paramètre aléatoire fixé à 42 afin d'assurer la reproductibilité. Le jeu de test n'est utilisé qu'à la fin pour évaluer la généralisation du modèle.

2.4 Modèle de régression linéaire

Le modèle estimé est une régression linéaire multiple, de la forme :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_{13} X_{13} + \varepsilon$$

Les coefficients sont estimés par la méthode des moindres carrés ordinaires (OLS) avec la bibliothèque `statsmodels`. Le modèle comprend une constante ainsi que les 13 variables explicatives. Aucune transformation ni normalisation particulière n'est appliquée aux variables avant l'ajustement.

2.5 Métriques d'évaluation

La performance du modèle est évaluée avec les métriques suivantes :

— coefficient de détermination R^2 ;

— erreur quadratique moyenne (MSE) ;

— racine carrée de l'erreur quadratique moyenne (RMSE).

Ces métriques sont calculées à la fois sur les données d'entraînement et sur les données de test afin d'évaluer le niveau d'ajustement et la capacité de généralisation.

2.6 Diagnostics du modèle

Les hypothèses du modèle sont vérifiées grâce à plusieurs outils :

— diagramme des résidus contre les prédictions ;

— test de Breusch-Pagan pour l'hétéroscédasticité ;

— facteur d'inflation de la variance (VIF) pour la multicolinéarité ;

— histogramme et QQ-plot des résidus pour la normalité ;

— test de Durbin-Watson pour l'autocorrélation.

3 Résultats

3.1 Performance du modèle

Les résultats du modèle sur les données d'entraînement et de test sont présentés dans le tableau ci-dessous.

TABLE 2 – Métriques de performance du modèle

Métrique	Entraînement	Test
R^2	0.750886	0.668759
MSE	21.641413	24.291119
RMSE	4.652033	4.928602

Ces mesures montrent que le modèle explique environ 75% de la variance de la cible sur l'échantillon d'apprentissage et 67% sur l'échantillon de test. La différence entre les deux performances reste acceptable, ce qui suggère une bonne capacité de généralisation sans sur-apprentissage excessif. Le RMSE de 4,93 milliers de dollars sur le test confirme une erreur de prédiction modérée mais non négligeable.

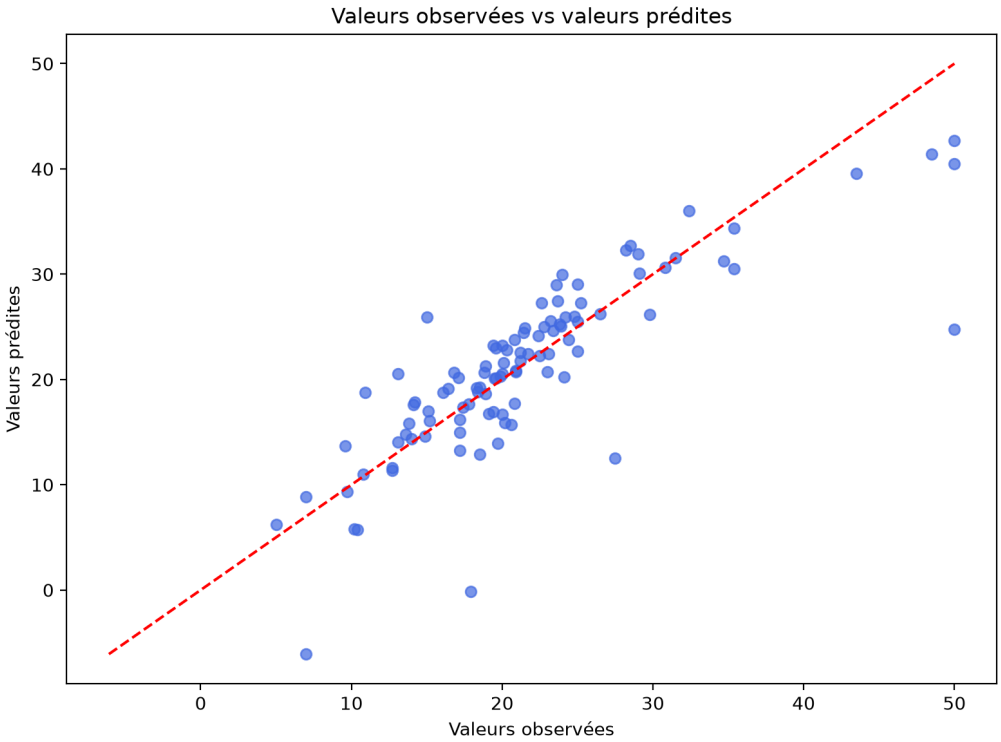


FIGURE 4 – Valeurs observées vs valeurs prédites

3.2 Interprétation des coefficients

Les coefficients estimés mettent en évidence les variables les plus influentes. Parmi les variables les plus déterminantes, on observe notamment :

— le nombre de pièces par logement : relation positive forte ;

— le pourcentage de population défavorisée : relation négative forte ;

— la distance aux centres d'emploi : relation négative ;

— le ratio élèves-professeurs : relation négative ;

— la présence de pollution atmosphérique : relation négative.

Les résultats sont cohérents avec l'intuition économique : des logements plus grands et mieux situés sont associés à des prix plus élevés, tandis que des quartiers moins favorisés ou plus pollués sont associés à des valeurs plus faibles.

4 Vérification des hypothèses du modèle

4.1 Hétéroscédasticité

Le diagramme des résidus par rapport aux prédictions montre une dispersion croissante à mesure que les prédictions augmentent. Le test de Breusch-Pagan confirme cette observation : la statistique vaut 59,189087 avec une p-value très faible, ce qui rejette l'hypothèse d'homoscédasticité. Les résidus ne sont donc pas homoscédastiques.

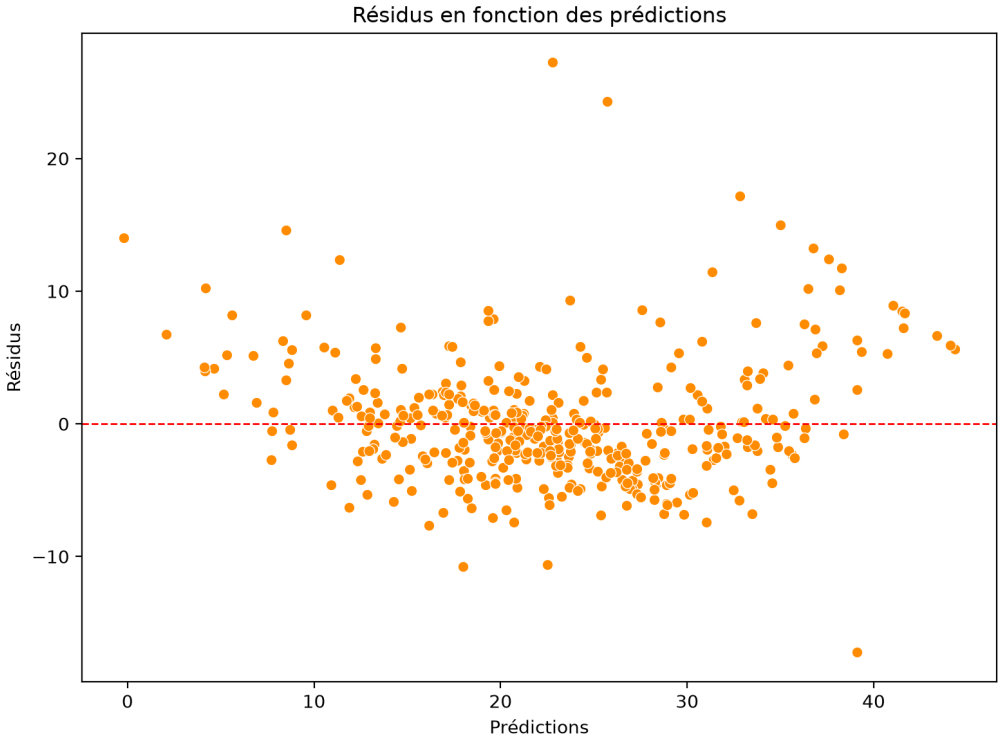


FIGURE 5 – Résidus vs prédictions

4.2 Normalité des résidus

Les tests de normalité indiquent une déviation significative par rapport à une loi normale. Le test de Shapiro-Wilk, ainsi que le QQ-plot, montrent que les résidus ne suivent pas exactement une distribution gaussienne. La même conclusion ressort des tests de Kolmogorov-Smirnov et d'Anderson-Darling.

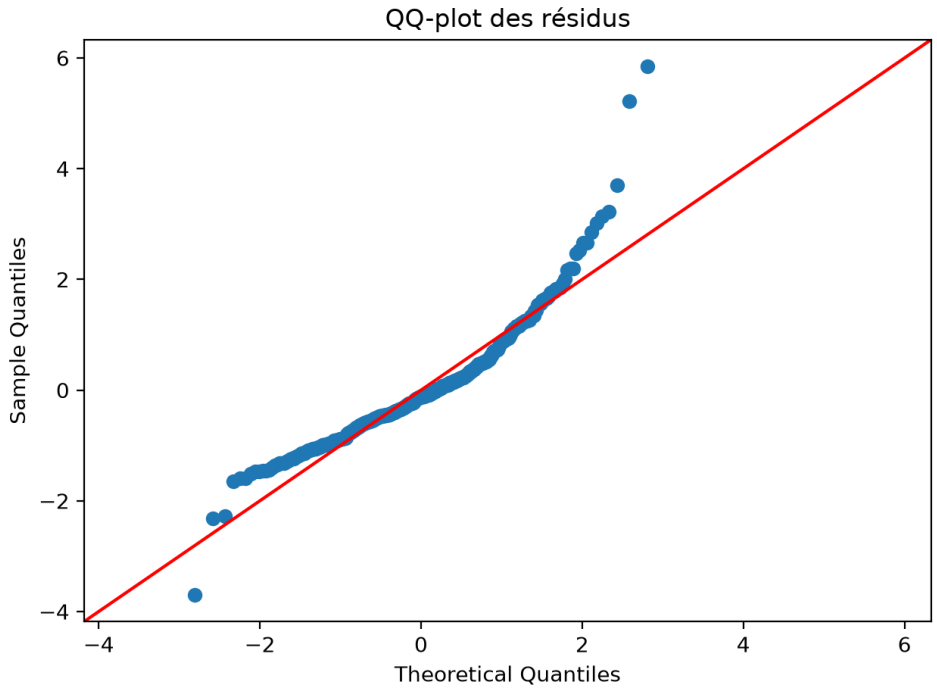


FIGURE 6 – QQ-plot des résidus

4.3 Autocorrélation et multicolinéarité

Le test de Durbin-Watson est proche de 2, ce qui suggère l'absence de corrélation résiduelle forte. Concernant la multicolinéarité, les valeurs VIF restent globalement acceptables, bien qu'un niveau de vigilance soit conseillé pour certaines variables fortement corrélées entre elles.

TABLE 3 – Synthèse des diagnostics du modèle

Diagnostic	Résultat	Interprétation
Breusch-Pagan	p-value $< 10^{-6}$	Hétéroscédasticité détectée
Durbin-Watson	2.114123	Pas de forte autocorrélation
Shapiro-Wilk	p-value $< 10^{-6}$	Non-normalité des résidus
Anderson-Darling	fort écart	Non-normalité confirmée
Kolmogorov-Smirnov	p-value $< 10^{-6}$	Distribution résiduelle non gaussienne

5 Discussion et limites

Le modèle de régression linéaire reste pertinent pour ce projet car il est interprétable et simple à expliquer. Il permet de comprendre l'influence relative des principales variables sur la valeur des logements. Cela en fait un bon point de départ pédagogique et analytique.

Cependant, plusieurs limites doivent être soulignées. Les hypothèses de normalité et d'homoscédasticité ne sont pas entièrement satisfaites, ce qui limite l'interprétation stricte des tests de significativité et des intervalles de confiance. De plus, les relations entre certaines variables et la cible semblent non linéaires, en particulier pour le pourcentage de

population défavorisée. Enfin, le jeu de données date de 1970 et ne reflète pas nécessairement le marché immobilier actuel.

Dans un travail ultérieur, il serait utile de tester des modèles plus avancés, tels qu'une régression régularisée, une régression log-linéaire ou un modèle non linéaire. On pourrait aussi utiliser une validation croisée pour stabiliser les performances et comparer plusieurs formulations du modèle.

6 Conclusion

Cette étude montre qu'une régression linéaire multiple permet d'expliquer une part substantielle de la variance du prix des logements à Boston. Avec un R^2 de 0,7509 sur l'entraînement et de 0,6688 sur le test, le modèle se révèle utile pour capturer les relations entre caractéristiques urbaines et valeur des logements. La baisse de performance entre entraînement et test reste modérée, ce qui laisse penser à une bonne capacité de généralisation.

Le projet a permis de mettre en pratique les étapes essentielles d'une analyse de données : préparation, exploration, modélisation, évaluation et diagnostic. Il a également démontré l'importance d'interpréter les résultats avec critique, car un modèle performant n'est pas forcément exempt de violations d'hypothèses. En ce sens, la régression linéaire constitue ici un bon point d'entrée dans le monde de la modélisation prédictive, tout en laissant place à des améliorations futures plus avancées.

7 Références

— Harrison, D., et Rubinfeld, D. L. (1978). Hedonic housing prices and the demand for clean air. *Journal of Environmental Economics and Management.*

— James, G., Witten, D., Hastie, T., et Tibshirani, R. (2013). *An Introduction to Statistical Learning.* Springer.

— Documentation scikit-learn.

— Documentation statsmodels.